

ÉCOLE MAROCAINE DES SCIENCES DE L'INGÉNIEUR  
EMSI

RAPPORT DE PROJET  
MODULE : DEEP LEARNING

---

# Implémentation et Analyse de Modèles de Deep Learning avec PyTorch

Classification d'images (Fashion-MNIST) et Analyse de sentiments (IMDb)

---

*Rédigé par :*

**ELFAROUKI**

**ABDERRAHMANE**

Élève Ingénieur

*Encadré par :*

**M.BATAL**

Enseignant - EMSI

Année Universitaire : 2025 – 2026

# Remerciements

Je tiens à exprimer mes plus sincères remerciements à mon professeur et à mon encadrant pour leur accompagnement, leurs conseils avisés et leur disponibilité tout au long de ce projet. Leur soutien a permis de guider les choix méthodologiques et d'approfondir la compréhension des concepts fondamentaux du deep learning. Je remercie également l'administration et le corps enseignant de l'École Marocaine des Sciences de l'Ingénieur pour les ressources pédagogiques mises à notre disposition. Enfin, je remercie toutes les personnes ayant contribué, de près ou de loin, à la réalisation de ce travail.

# Résumé

Ce rapport présente la conception, l'implémentation et l'évaluation de deux architectures de réseaux de neurones profonds développées avec le framework PyTorch. La première partie est consacrée à la classification d'images à partir du jeu de données Fashion-MNIST, tandis que la seconde traite de l'analyse de sentiments sur le corpus IMDb. L'objectif principal de ce travail est de montrer comment concevoir, entraîner et évaluer des modèles de deep learning de manière modulaire, reproductible et interprétable, tout en mettant en évidence les performances obtenues ainsi que les limites associées aux approches retenues.

# Table des matières

|                                                             |           |
|-------------------------------------------------------------|-----------|
| <b>Remerciements</b>                                        | <b>1</b>  |
| <b>Résumé</b>                                               | <b>2</b>  |
| <b>1 Introduction générale</b>                              | <b>4</b>  |
| 1.1 Contexte scientifique et académique . . . . .           | 4         |
| 1.2 Problématique . . . . .                                 | 4         |
| 1.3 Objectifs du projet . . . . .                           | 4         |
| 1.4 Méthodologie générale . . . . .                         | 4         |
| <b>2 Données et prétraitement</b>                           | <b>6</b>  |
| 2.1 Jeu de données Fashion-MNIST . . . . .                  | 6         |
| 2.1.1 Description des classes . . . . .                     | 6         |
| 2.1.2 Prétraitement appliqué . . . . .                      | 6         |
| 2.2 Jeu de données IMDb . . . . .                           | 6         |
| 2.2.1 Prétraitement textuel . . . . .                       | 7         |
| <b>3 Méthodologie et architectures</b>                      | <b>8</b>  |
| 3.1 Architecture du modèle CNN pour Fashion-MNIST . . . . . | 8         |
| 3.1.1 Formalisme de l'architecture . . . . .                | 8         |
| 3.2 Architecture du modèle NLP pour IMDb . . . . .          | 8         |
| 3.3 Choix d'optimisation . . . . .                          | 9         |
| <b>4 Résultats expérimentaux</b>                            | <b>10</b> |
| 4.1 Résultats obtenus sur Fashion-MNIST . . . . .           | 10        |
| 4.2 Résultats obtenus sur IMDb . . . . .                    | 11        |
| 4.3 Analyse interprétative des résultats . . . . .          | 12        |
| <b>5 Discussion et limites</b>                              | <b>13</b> |
| 5.1 Limites du modèle CNN . . . . .                         | 13        |
| 5.2 Limites du modèle NLP . . . . .                         | 13        |
| 5.3 Perspectives d'amélioration . . . . .                   | 13        |
| <b>6 Conclusion générale</b>                                | <b>14</b> |

# Chapitre 1

## Introduction générale

### 1.1 Contexte scientifique et académique

L'évolution rapide des techniques d'apprentissage profond a profondément transformé plusieurs domaines de recherche et d'application, notamment la vision par ordinateur, le traitement automatique du langage naturel et l'analyse de données complexes. Dans ce contexte, le deep learning s'impose aujourd'hui comme une approche de référence pour résoudre des problèmes de classification, de prédiction et de génération. Les réseaux de neurones profonds, grâce à leur capacité à extraire automatiquement des représentations hiérarchiques à partir des données, ont permis d'atteindre des performances très élevées sur des tâches variées.

### 1.2 Problématique

Le présent projet s'inscrit dans cette dynamique en proposant l'implémentation et l'évaluation de deux modèles de deep learning sur deux tâches distinctes : la classification d'images et l'analyse de sentiments. La première tâche repose sur l'utilisation d'un réseau convolutif appliqué au jeu de données Fashion-MNIST, tandis que la deuxième repose sur un modèle simple basé sur des embeddings pour classer des critiques de films extraites du corpus IMDb. Ce choix permet d'illustrer la polyvalence du framework PyTorch et de comparer deux modalités d'apprentissage adaptées à des types de données différents.

### 1.3 Objectifs du projet

Ce projet a pour objectifs principaux de :

- mettre en œuvre un modèle de classification d'images à partir d'un réseau convolutif ;
- développer un modèle de classification binaire de textes basé sur des embeddings ;
- analyser l'évolution de la fonction de perte au cours de l'entraînement ;
- évaluer les performances des modèles sur des jeux de test indépendants ;
- interpréter les erreurs commises et discuter des limites des architectures retenues.

### 1.4 Méthodologie générale

La démarche adoptée repose sur une approche expérimentale et itérative. Elle consiste à définir une architecture adaptée à chaque tâche, entraîner le modèle sur un jeu de données d'apprentissage, mesurer ses performances sur un jeu de test, puis analyser les

résultats obtenus. Les expérimentations sont réalisées avec Python et le framework PyTorch, dans un environnement structuré et modulaire permettant une reproduction simple de l'ensemble des résultats.

# Chapitre 2

## Données et prétraitement

### 2.1 Jeu de données Fashion-MNIST

Fashion-MNIST est un ensemble de données de référence utilisé pour l'évaluation des modèles de vision par ordinateur. Il contient 70 000 images en niveaux de gris, représentant des vêtements, réparties en 10 classes distinctes. Chaque image possède une résolution de  $28 \times 28$  pixels. Le jeu d'entraînement contient 60 000 exemples, tandis que le jeu de test contient 10 000 exemples.

#### 2.1.1 Description des classes

Les classes du dataset sont les suivantes : T-shirt, pantalon, pull, robe, manteau, sandale, chemise, sneaker, sac et bottine. Cette diversité de catégories rend la tâche plus réaliste qu'un simple problème de reconnaissance de chiffres, comme dans le jeu de données original MNIST.

#### 2.1.2 Prétraitement appliqué

Les images sont transformées selon une chaîne de prétraitement commune afin d'optimiser la convergence du modèle. En particulier :

- conversion des images en tenseurs PyTorch ;
- normalisation des valeurs de pixels pour centrer les données autour de zéro ;
- standardisation des caractéristiques afin d'améliorer la stabilité de l'apprentissage.

La transformation retenue est de la forme :

$$x' = \frac{x - 0.5}{0.5}$$

Cette opération permet de ramener les intensités de pixels dans un intervalle plus favorable à l'optimisation par descente de gradient.

### 2.2 Jeu de données IMDB

Le jeu de données IMDB est un corpus de critiques de films annotées comme positives ou négatives. Il est couramment utilisé pour des tâches de classification binaire en traitement automatique du langage naturel. Le corpus comporte un grand nombre de phrases relativement longues, ce qui en fait un bon point de départ pour expérimenter des modèles simples d'analyse de sentiments.

### 2.2.1 Prétraitement textuel

Le prétraitement textuel appliqué au corpus IMDb comprend plusieurs étapes :

1. conversion du texte en minuscules ;
2. tokenisation par séparation sur les espaces ;
3. troncature à une longueur maximale de 50 mots ;
4. conversion en indices entiers à partir d'un vocabulaire construit à partir du corpus d'entraînement ;
5. ajout de tokens de padding pour obtenir une séquence de taille fixe.

Ce prétraitement simplifié permet de réduire la complexité computationnelle tout en conservant une représentation exploitable du texte.



# Chapitre 3

## Méthodologie et architectures

### 3.1 Architecture du modèle CNN pour Fashion-MNIST

Le modèle CNN conçu pour la classification d'images, nommé **FashionCNN**, repose sur une architecture convolutive compacte et efficace. Elle est composée de :

- une première couche de convolution suivie d'une activation ReLU ;
- une couche de pooling maximale ;
- une seconde couche de convolution suivie d'une activation ReLU ;
- une seconde couche de pooling maximale ;
- une couche de flattening ;
- une couche linéaire dense ;
- une couche de dropout ;
- une couche de sortie de taille 10 correspondant aux classes du dataset.

Cette architecture permet d'extraire progressivement des caractéristiques locales puis plus globales à partir des images d'entrée. Les couches de pooling contribuent à réduire la taille spatiale des représentations tout en conservant les informations les plus discriminantes.

#### 3.1.1 Formalisme de l'architecture

Le traitement d'une image d'entrée peut être résumé par la séquence suivante :

$(1, 28, 28) \rightarrow \text{Conv} \rightarrow \text{ReLU} \rightarrow \text{MaxPool} \rightarrow \text{Conv} \rightarrow \text{ReLU} \rightarrow \text{MaxPool} \rightarrow \text{Flatten} \rightarrow \text{Linear} \rightarrow \text{Dropout}$

### 3.2 Architecture du modèle NLP pour IMDB

Le modèle utilisé pour l'analyse de sentiments est un modèle simple basé sur des embeddings. Il est composé de :

- une couche d'embedding permettant de représenter chaque mot par un vecteur dense ;
- une moyenne sur les embeddings de la séquence ;
- une couche linéaire de sortie produisant une valeur scalaire interprétée comme un score de sentiment.

Cette approche est simple, rapide et adaptée à des expérimentations pédagogiques. Elle permet d'introduire les bases de l'apprentissage sur des données textuelles sans recourir à des architectures plus lourdes telles que les LSTM ou les Transformers.

### 3.3 Choix d'optimisation

Les modèles sont entraînés avec l'optimiseur Adam et des fonctions de perte adaptées à la tâche :

- **Fashion-MNIST** : CrossEntropyLoss ;
- **IMDb** : BCEWithLogitsLoss.

Le choix de l'optimiseur Adam est motivé par sa capacité à converger rapidement sur des problèmes de classification, tout en restant relativement simple à mettre en œuvre.

# Chapitre 4

## Résultats expérimentaux

### 4.1 Résultats obtenus sur Fashion-MNIST

Le modèle CNN a été entraîné pendant 5 époques. L'évolution de la perte observée au cours de l'apprentissage montre une décroissance régulière, signe d'une optimisation stable.

TABLE 4.1 – Évolution de la loss sur Fashion-MNIST

| Époque | Loss cumulée |
|--------|--------------|
| 1      | 392.2036     |
| 2      | 260.4079     |
| 3      | 220.8927     |
| 4      | 195.9680     |
| 5      | 175.7602     |

L'évaluation sur le jeu de test donne une précision globale de :

$$\text{Accuracy} = 91.13\%$$




FIGURE 4.1 – Évolution de la fonction de perte du modèle FashionCNN au cours de l'entraînement.




FIGURE 4.2 – Exemples de prédictions incorrectes réalisées par le modèle FashionCNN.

## 4.2 Résultats obtenus sur IMDb

Le modèle d'analyse de sentiments a également été entraîné sur 5 époques. Les valeurs de perte observées décroissent progressivement, confirmant un apprentissage effectif malgré la simplicité de l'architecture retenue.

TABLE 4.2 – Évolution de la loss sur IMDb

| Époque | Loss cumulée |
|--------|--------------|
| 1      | 265.3129     |
| 2      | 232.0837     |
| 3      | 207.9863     |
| 4      | 191.1311     |
| 5      | 178.6923     |

La précision globale obtenue sur le jeu de test est de :

$$\text{Accuracy} = 78\%$$




FIGURE 4.3 – Courbe de perte du modèle SentimentModel

### 4.3 Analyse interprétative des résultats

L'analyse des performances met en évidence plusieurs points importants. D'une part, le modèle CNN offre de bonnes performances sur les images de Fashion-MNIST. D'autre part, le modèle d'analyse de sentiments, bien que fonctionnel, reste limité par la simplicité de sa représentation textuelle. Les erreurs observées peuvent être attribuées à la perte d'information liée à la moyenne globale des embeddings et à la troncature des séquences de texte.

# Chapitre 5

## Discussion et limites

### 5.1 Limites du modèle CNN

Le modèle CNN présente plusieurs limites. Parmi elles :

- sa capacité à généraliser peut être améliorée par augmentation de données ;
- l’architecture reste relativement simple ;
- certaines confusions persistent entre classes similaires.

### 5.2 Limites du modèle NLP

Le modèle NLP proposé est un point de départ pédagogique, mais il présente des limites importantes :

- il ne capture pas explicitement l’ordre des mots ;
- il peut perdre des informations sur les textes longs ;
- il ne prend pas en compte les dépendances contextuelles complexes.

### 5.3 Perspectives d’amélioration

Pour améliorer les performances et la robustesse des modèles, plusieurs pistes peuvent être explorées :

- l’ajout de couches convolutionnelles ou d’architectures plus profondes ;
- l’utilisation de réseaux récurrents ou de Transformers pour le texte ;
- l’intégration de techniques d’augmentation de données ;
- l’évaluation sur des jeux de données plus volumineux ;
- l’exploration d’une accélération GPU pour réduire le temps d’entraînement.

# Chapitre 6

## Conclusion générale

Ce projet a permis de mettre en œuvre deux pipelines complètes de deep learning avec PyTorch, l'un dédié à la vision par ordinateur et l'autre à l'analyse de sentiments. Les résultats obtenus démontrent l'intérêt d'une approche modulaire et structurée pour concevoir, entraîner et évaluer des modèles de neurones profonds. Bien que les performances soient satisfaisantes dans un cadre académique, plusieurs améliorations sont encore possibles, notamment par l'intégration d'architectures plus avancées et l'utilisation de ressources de calcul plus importantes.

# Bibliographie

- [1] Adam Paszke, Sam Gross, Francisco Massa, et al. *PyTorch : An Imperative Style, High-Performance Deep Learning Library*. Advances in Neural Information Processing Systems 32 (NeurIPS 2019).
- [2] Han Xiao, Kashif Rasul, Roland Vollgraf. *Fashion-MNIST : a Novel Image Dataset for Benchmarking Machine Learning Algorithms*. arXiv :1708.07747, 2017.
- [3] Andrew L. Maas, Raymond E. Daly, Peter T. Pham, Dan Huang, Andrew Y. Ng, and Christopher Potts. *Learning Word Vectors for Sentiment Analysis*. Association for Computational Linguistics (ACL), 2011.